MLP para Regresión y Clasificación: Garment Productivity y MAGIC Gamma Telescope

Documento realizado por

Jesus David Gelves Cajiao
Facultad de ingenieria
Universidad San Buenaventura de Cali,
Colombia
30000098650
jdgelvesc@correo.usbcali.edu.co

Lina Maria Fernandez Garcia
Facultad de ingenieria
Universidad San Buenaventura de Cali,
Colombia
30000095421
lmfernandezg1@correo.usbcali.edu.co

Resumen— Este trabajo implementa redes neuronales multicapa (MLP) para abordar problemas de regresión y clasificación y analiza cómo los hiperparámetros (arquitectura, funciones de activación, optimizador, regularización) influyen en el desempeño y la generalización. En regresión, se utiliza el conjunto Productivity Prediction of Garment Employees (UCI) para modelar la productividad real de líneas de confección a partir de variables operativas, y en este se emplean métricas como MSE y R^2 para evaluar error y ajuste; en clasificación, se utilizan precisión, recall, F1 y AUC-ROC, priorizando interpretaciones robustas en presencia de desbalance. Como caso de estudio de clasificación, se utiliza el dataset MAGIC Gamma Telescope (UCI), donde la tarea es distinguir entre eventos gamma (señal) y hadrón (fondo). Los resultados evidencian que aumentar la capacidad de representación y elegir un optimizador adecuado puede mejorar la separabilidad (AUC) y el equilibrio precisión-recall (F1), mientras que una regularización excesiva conduce a subajuste.

Palabras clave— Redes neuronales, perceptrón multicapa, regresión, clasificación binaria, hiperparámetros, optimización, regularización.

I. Introducción

Las redes neuronales artificiales constituyen una de las herramientas más potentes del aprendizaje automático para modelar relaciones no lineales entre variables. El perceptrón multicapa (MLP) [1] En este trabajo se abordan dos problemas fundamentales del aprendizaje supervisado: regresión y clasificación.

Para la regresión, se utiliza el conjunto de datos Productivity Prediction of Garment Employees del repositorio UCI [2], que recoge mediciones operativas de líneas de producción (por ejemplo, tiempo extra, incentivos, WIP, número de trabajadores y cambios de estilo) y una variable objetivo de productividad real. El objetivo es construir MLP que minimicen el error de predicción y maximicen el ajuste global, evaluados con métricas como MAE, RMSE y R^2 [3, 4].

Para la clasificación, se emplea el conjunto MAGIC Gamma Telescope del repositorio UCI [5], con descriptores geométricos y de intensidad de imágenes Cherenkov. La tarea consiste en distinguir entre eventos de rayos gamma (señal) y hadrones (fondo). En esta parte se considera gamma como clase positiva y se reportan accuracy, precision, recall, F1 y AUC-ROC [6], además de matrices de confusión [7].

En ambas tareas se diseñan tres configuraciones de MLP que varían la profundidad (número de capas ocultas) y el ancho (neuronas por capa), así como las funciones de activación, los optimizadores (por ejemplo, Adam y SGD [8] con momentum [9]) y la regularización (L2 y early stopping [10]). El preprocesamiento incluye codificación/limpieza, división entrenamiento prueba (estratificada en clasificación) y estandarización (ajustada solo con entrenamiento para evitar data leakage). Este protocolo permite estudiar, de forma controlada, cómo influyen los hiperparámetros en la capacidad de generalización: una mayor capacidad representacional y una optimización adecuada suelen mejorar el rendimiento siempre que se limite el sobreajuste; en cambio, una penalización excesiva puede aumentar el sesgo y degradar la precisión de los modelos.

II. Problemas

En este proyecto se abordaron dos problemas distintos utilizando redes neuronales multicapa. Uno corresponde a una tarea de regresión y el otro de clasificación, para esto se utilizaron datasets específicos que permitieran entrenar y evaluar los diferentes modelos de acuerdo con la naturaleza de cada problema. A continuación, se presentan en detalle ambos enfoques, junto con sus características y objetivos.

A. Predicción de la Productividad en la Industria Textil

Para el primer problema se utilizó el dataset *Productivity Prediction of Garment Employees* del repositorio de Machine Learning de UC Irvine [2]. Este conjunto de datos recopila información de los procesos de fabricación de prendas y la productividad de los empleados, con el fin de utilizar dicha información para predecir el nivel de productividad de los empleamos en la industria textil en un rango de 0 a 1.

El dataset presenta diferentes variables relacionadas con la jornada laboral, atributos de los equipos de trabajo y factores de producción, distribuidas en 14 características de tipo numérico continuo y categórico, contando con 1197

instancias. Entre estas características se incluyen variables como día, trimestre, equipo, número de trabajadores, tiempo de inactividad, trabajo en proceso, productividad objetivo, entre otras. En este contexto, la variable objetivo corresponde a la productividad real. Además, es importante resaltar que la variable del trabajo en progreso contiene valores faltantes lo que se debe considerar durante el procesamiento de la información.

B. Clasificación de MAGIC Gamma Telescope

El objetivo de este trabajo es resolver un problema de clasificación binaria utilizando redes neuronales artificiales de tipo perceptrón multicapa (MLP)[1]. La tarea consiste en distinguir entre eventos de rayos gamma y eventos de hadrones detectados por el telescopio MAGIC [5].

El conjunto de datos utilizado [5] consta de 19,020 instancias y 11 atributos, incluyendo la clase objetivo (gamma y hadron). Los primeros 10 atributos son mediciones físicas continuas que describen las propiedades de las "imágenes" de los eventos, mientras que el atributo final, class, es la etiqueta categórica, con g para gamma y h para hadrón. El objetivo es entrenar un modelo que, a partir de las 10 mediciones, sea capaz de predecir correctamente la clase del evento.

En la tabla 1 se resume cada atributo con una descripción resumida basada en la documentación del dataset.

TABLE I. ATRIBUTOS DEL DATASET

Atributo	Descripción
fLength	Longitud (eje mayor) de la imagen; medida geométrica principal.
fWidth	Ancho (eje menor) de la imagen; complementa a fLength.
fSize	Tamaño total de luz (suma de señales); aproximación a la energía del evento.
fConc	Concentración de luz: fracción en los píxeles más brillantes (compacidad).
fConc1	Concentración en el píxel más brillante (pico de intensidad).
fAsym	Asimetría de la distribución de luz respecto al centroide.
fM3Long	Momento de orden 3 a lo largo del eje mayor (cola/forma longitudinal).
fM3Trans	Momento de orden 3 a lo largo del eje menor (forma transversal).
fAlpha	Ángulo entre el eje mayor y la dirección al centro de la cámara (orientación).

En la Tabla 1, los atributos combinan geometría (fLength, fWidth), energía/concentración (fSize, fConc, fConc1) y descriptores de forma/orientación (fAsym, f fM3Long, fM3Trans, fAlpha, fDist). Esta diferencia de datos hace recomendable la estandarización previa al entrenamiento, ya que cada grupo opera en escalas físicas diferentes.

III. METODOLOGÍA

A partir de lo anterior, se diseñaron tres configuraciones diferentes de modelos para cada problema (regresión y clasificación), con el propósito de comparar y analizar sus resultados. En esta sección se describen los modelos de redes neuronales que fueron implementados, los hiperparámetros evaluados y el proceso de entrenamiento.

En el caso de la predicción de la productividad en la industria textil, antes de comenzar con la construcción de los modelos y su entrenamiento, se realizó un procesamiento a los datos de la siguiente forma:

- Extraer las características de la variable fecha y eliminar su columna ya que era una cadena de texto.
- Eliminar la columna *wip* porque presenta valores faltantes lo que generaba la situación "Not a Number".
- Usar *one-hot encoding* para convertir las variables categóricas.
- Dividir los datos en entrenamiento y prueba.
- Escalar las características numéricas.

Con la preparación del dataset previa se procedió a definir el primer modelo. Este consiste en una arquitectura clásica de tres capas ocultas con funciones de activación *ReLU* cuya función es la siguiente*:*

$$f(\mathrm{x}) = \max(0, \mathrm{x}) \tag{1}$$

Además, tiene una capa de salida lineal para la predicción del valor continuo. Estas capas cuentan con 64, 32 y 16 neuronas, respectivamente. Para el entrenamiento se utilizó el optimizador Adam [8] que se define de las siguientes ecuaciones:

$$p_t = m_1 \times p_{t-1} + (1 - m_1) \times g_t \tag{2}$$

$$q_t = m_2 \times q_{t-1} + (1 - m_2) \times g_t^2 \tag{3}$$

Las ecuaciones que se muestran en (1)(2) (pt y qt) son las medias móviles que utiliza Adam para calcular las tasas de aprendizaje adaptativas y se hace uso con una tasa de aprendizaje de 0,001 y la función de pérdida del error cuadrático medio (MSE) [3] definida:

$$MSE = \frac{1}{n}\sum_{i=1}^{n}(y_i - \tilde{y}_i)^2 \tag{4}$$

$$RMSE = \sqrt{\sum_{i=1}^{n}\frac{(y_i - \tilde{y}_i)^2}{n}} \tag{5}$$

$$MAE = \frac{1}{n}\sum_{i=1}^{n}|y_i - \tilde{y}| \tag{6}$$

$$R^2 = \frac{\sum_{i=1}^{n}(\tilde{y}_i - \bar{y})^2}{\sum_{i=1}^{n}(y_i - \bar{y})^2} \tag{7}$$

El modelo se entrenó durante 200 épocas, utilizando un *batch size* de 32 y reservando el 20% de los datos para la validación. Tras finalizar el entrenamiento, se evaluó el conjunto de prueba con las métricas de perdida (4) (MSE), raíz del error cuadrático medio (RMSE) (5), error absoluto

medio (MAE) (6), y el coeficiente de determinación (R^2) (7) [3, 4].

El segundo modelo se construyó reduciendo el número de capas ocultas a dos, donde la primera capa oculta contó con 128 neuronas y la segunda con 64, ambas con la función de activación *ReLU* [11] y regularización:

$$\mathrm{L2} = 1 \times 10^{-2} \tag{8}$$

En (8) está el L2 de 0.01, empleando la técnica de *Dropout* con 0.3. Para esta configuración, se conservó el optimizador Adam, pero con una taza de aprendizaje más alta (0,01), además se utilizó un *callbacks* de *Early Stopping* para evitar sobreentrenar. De esta forma, se buscó prevenir el sobreajuste y acelerar el aprendizaje.

En este caso, las épocas definidas fueron 300 pero gracias a la implementación de *Early Stopping* el entrenamiento se detuvo de manera anticipada al no observar mejoras significativas. También, se modificó el tamaño de lote a 16 y manteniendo el 20% de los datos para la validación. De igual forma, se usaron las métricas descritas anteriormente para evaluar el conjunto de prueba.

Finalmente, para el último modelo se volvieron a definir tres capas ocultas con 64, 32 y 16 neuronas, pero en esta ocasión utilizando la función de activación tangente hiperbólica [11] junto con una regularización como en (8). De nuevo, se empleó el optimizador Adam con una taza de aprendizaje reducida a 0,0005 y la técnica de *Early Stopping* con una paciencia de 15 épocas, monitoreando la función de pérdida.

El entrenamiento se configuro con un máximo de 300 épocas, pero debido a la técnica de *callbacks* se interrumpió de manera anticipada al no evidenciar mejoras, además, se regresó a un tamaño de lote de 32, asignando el 20% de datos a la validación. Posteriormente, el modelo fue evaluado con las métricas que se describieron antes sobre el conjunto de prueba.

Es importante resaltar que, las métricas empleadas en la evaluación del conjunto de prueba de los últimos dos modelos fueron las mismas que se utilizaron en el primero (MSE, RMSE, MAE y R^2). Ya que, el uso consistente de estas métricas permite no solo analizar y visualizar los resultados obtenidos por cada modelo, si no también realizar una comparación objetiva entre ellos y extraer conclusiones más sólidas sobre su rendimiento.

Siguiendo esta línea, para el segundo dataset llamado MAGIC Gamma Telescope, se orienta de la misma manera en revisar el comportamiento de las redes neuronales multicapa (MLP) aplicadas a la discriminación de eventos gamma frente a eventos hadrónicos en el conjunto de datos. Para el estudio se hará uso de la API de Keras utilizada para construir y entrenar los modelos [12].

El problema se formula como una clasificación binaria, cada registro representa un evento observado por el telescopio MAGIC y esta descrito por diez atributos que caracterizan la imagen Cherenkov como se mostró en la Tabla 1. La etiqueta de salida toma dos valores: g (gamma) y h (hadrón).

Al principio las etiquetas de codificaron como 1 para gamma y 0 para hadrón, a su vez, se aplicó un escalado estándar donde la media y la varianza se calcularon únicamente con el conjunto de entrenamiento y luego se usaron para transformar también los datos de prueba. Esto se hizo para evitar cualquier tipo de "filtración" de información entre los conjuntos.

Los datos se dividieron de forma proporcional en un 75% para entrenamiento y un 25% para prueba. Esta división aseguró que cada clase se mantuviera igual en ambos conjuntos, lo que facilita una comparación justa de los resultados.

Para los modelos, estos fueron tres con una capa de salida sigmoide:

$$\sigma(z) = \frac{1}{1 + e^{-z}} \tag{9}$$

Y funciones de activación distintas en las capas ocultas, además de cambios en optimización y regularización.

Empezando por el primer modelo llamado “Modelo A” este fue el punto de partida. Es un modelo sencillo con una sola capa oculta de 32 neuronas y activación ReLU. Usamos el optimizador Adam con una tasa de aprendizaje de 0.001 y aplicamos una pequeña regularización:

$$\mathrm{L2} = 1 \times 10^{-4} \tag{10}$$

En (10) el 0.0001 es un valor muy pequeño lo que indica que se aplicó una penalización leve. El objetivo es encontrar un equilibrio. La regularización debe ser lo suficientemente fuerte para prevenir el sobreajuste, pero no tan fuerte como para que el modelo no pueda aprender lo suficiente.

Para el segundo “Modelo B”, fue diseñado para ser más complejo. A diferencia del primero, este tiene una arquitectura más profunda con dos capas ocultas, una de 128 neuronas y otra de 64, para este la función de activación es tanh (tangente hiperbólica):

$$f(x) = \frac{(e^{x} - e^{-x})}{(e^{x} + e^{-x})} \tag{11}$$

Se usa (11) en lugar de ReLU. En este caso, decidimos cambiar el optimizador a SGD con momentum cuya ecuación es:

$$v_{t+1} = \beta v_t + \alpha \nabla L(w_t) \tag{12}$$

$$w_{t+1} = \beta v_t + \alpha \nabla L(w_t) \tag{13}$$

Por lo tanto, en (12) y (13) la actualización de los pesos del modelo (w_t) se realiza utilizando el gradiente de la función de pérdida ($\nabla L(w_t)$ y un vector de velocidad (v_t). Este vector de velocidad, que representa el "impulso" acumulado de los gradientes anteriores, se actualiza en cada paso (v_{t+1}) combinando el vector de velocidad anterior (v_t) con el gradiente actual. Finalmente, los pesos se actualizan restando este nuevo vector de velocidad. Este proceso se rige

por la tasa de aprendizaje (α), que determina el tamaño del paso, y un factor de momentum (β) de 0.9, que controla la inercia del movimiento. Esta configuración nos permitió acelerar significativamente el entrenamiento y analizar el impacto de este esquema de optimización en el rendimiento del modelo.

Por último, el "Modelo C", nos enfocamos en el problema del sobreajuste. Es un modelo intermedio con una sola capa oculta de 64 neuronas y la función de activación sigmoide. Aunque se usa el mismo optimizador Adam y tasa de aprendizaje de 0.001 que en el Modelo A, el cambio clave aquí fue aumentar significativamente la regularización que se usó en (8), este valor, que es 100 veces más grande que el de los otros modelos, aplicó una penalización mucho más fuerte. El objetivo era probar si una regularización más agresiva nos ayudaba a encontrar un mejor equilibrio entre un modelo que aprende bien y uno que no se memoriza los datos de entrenamiento.

Y como función de activación de salida, en clasificación binaria se emplea sigmoide [11], que mapea la salida real a una probabilidad entre 0 y 1.

En (9) evidenciamos una salida de una probabilidad de que el rayo sea gamma. Para convertir esta probabilidad en una decisión final, usamos un umbral. La regla más sencilla es un umbral de 0.5, si la probabilidad es mayor, se clasifica como gamma, y si es menor, como hadrón. Sin embargo, este umbral se puede ajustar según lo que sea más importante para nosotros. Por ejemplo, si necesitamos identificar el mayor número de rayos gamma posible para un experimento (maximizar el *recall*), podemos bajar el umbral para ser menos estrictos.

A su vez, se usó una función de perdida para ajustar las probabilidades, la cual es la entropía cruzada binaria (BCE) [3].

$$L_{BCE} = -((y \times log(p) + (1 - y) \times log(1 - p)) \quad (14)$$

En (4) donde p es (3) el BCE penaliza con fuerza las predicciones muy seguras pero incorrectas, guiando al optimizador a asignar alta probabilidad a gamma cuando la evidencia en las características lo respalda.

Para el entrenamiento, se empleó validación interna (20% del entrenamiento) con Early Stopping con 12 de patience, y ReduceLROnPlateau para estabilizar la convergencia y evitar sobreajuste. Adam se utilizó por su rapidez de convergencia, SGD con momentum y Nesterov se evaluó en el modelo profundo ("Modelo B") para observar diferencias en la trayectoria de optimización.

Finalmente, como métricas de evaluación de hizo uso de recall, F1 y AUC (Area Bajo la Curva), priorizando la clase gamma como positiva.

$$Prec = \frac{TP}{TP + FP},\ Rec = \frac{TP}{TP+FN},\ F1 = \frac{2PrecRec}{Prec+Rec} \quad (15)$$

En (5) las variables clave en estas fórmulas (TP, FP, FN) provienen de una matriz de confusión, que es una tabla que resume el rendimiento de un modelo de clasificación. El TP (Verdaderos Positivos) son los casos que el modelo predijo correctamente como positivos. El FP (Falsos Positivos) son los casos que el modelo clasificó como positivos, pero que en realidad eran negativos; un error de tipo I. Finalmente, el FN (Falsos Negativos) son los casos que el modelo no detectó, es decir, eran positivos, pero los clasificó como negativos.

La puntuación F1 es el promedio de la precisión y el recall. Su propósito es balancear ambas métricas en un solo valor. Si un modelo tiene una precisión muy alta pero un recall muy bajo (o viceversa), su puntuación F1 será baja, lo que lo penaliza. Esto la convierte en una métrica muy útil, especialmente en conjuntos de datos con clases desequilibradas como es el caso del dataset de MAGIC Gamma Telescope, donde una simple exactitud (accuracy) puede ser engañosa y no reflejar el verdadero rendimiento del modelo.

El análisis de estas métricas se complementa con el AUC de la curva ROC, que evalúa la capacidad del modelo para separar las clases en todos los posibles umbrales.

IV. RESULTADOS

Con base en la metodología descrita previamente, se presentan los resultados obtenidos de la evaluación de los diferentes modelos diseñados para cada problema. Para esto, se muestran los valores de las métricas de desempeño y graficas que permiten visualizar el comportamiento del tuvieron los entrenamientos.

A. Resultados de la Predicción de Productividad en la Industria Textil

En primer lugar, para facilitar la comparación de los resultados de los tres modelos, en la Tabla 2 se presentan las métricas calculadas en el conjunto de prueba. Aquí se incluyen los valores de MSE, RMSE, MAE y R^2 por cada modelo.

TABLE II. COMPARACIÓN DE DESEMPEÑO DE LOS MODELOS DE REGRESIÓN

Modelo	MSE	RMSE	MAE	R^2
Modelo A	0.0359	0.1896	0.1289	- 0.3533
Modelo B	0.0265	0.1628	0.1166	0.1624
Modelo C	0.0276	0.1662	0.0962	0.2986

Asimismo, se tienen las gráficas de curva de pérdida que permiten visualizar como está evolucionando el error (MSE) de cada modelo a lo largo de las épocas, además de indicar si el este realmente está aprendiendo o no. Para esto, se grafica la perdida calculada en los datos de entrenamiento (Train Loss) y la perdida en el conjunto de validación (Val Loss).

En la Fig. 1 se observa la gráfica del primer modelo, donde la línea de perdida de entrenamiento y de validación tiene una disminución rápida en las primeras épocas. Sin embargo, la pérdida de validación deja de descender y muestra un comportamiento más irregular, mientras que la pérdida de entrenamiento sigue disminuyendo hasta estabilizarse.

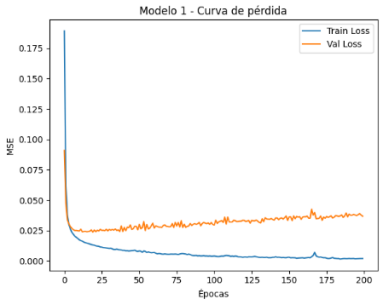

Fig. 1. Gráfica Curva de Pérdida del Modelo 1

Por su parte, la Fig. 2 que presenta la curva de pérdida del segundo modelo, muestra que tanto la perdida de entrenamiento como la de validación descienden rápidamente en las primeras épocas, para luego estabilizarse en valores bajos y cercanos entre sí.

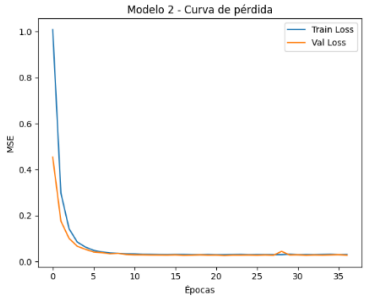

Fig. 2. Gráfica Curva de Pérdida del Modelo 2

En la Fig. 3, con el tercer modelo se evidencia nuevamente como la perdía de entrenamiento y la de validación disminuye aún más rápido, ambas presentando valores cercanos entre sí. Aunque la perdida de validación se muestra con pequeñas irregularidades.

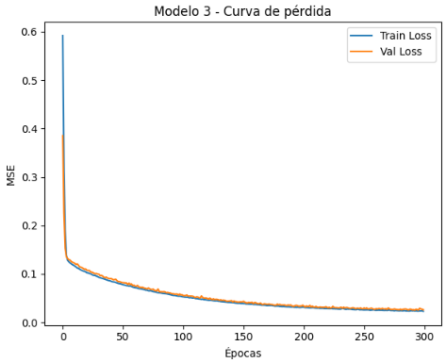

Fig. 3. Gráfica Curva de Pérdida del Modelo 3

De manera complementaria, se presentan las gráficas de comparación de series de los valores reales contra los predichos, con el objetivo de evaluar cómo se comportan las predicciones frente a los datos reales. En ese sentido, se traza una línea azul que representan los valores reales de la variable objetivo, mientras que la línea roja discontinua muestra los valores predichos por el modelo. Esto permite observar si el modelo sigue la tendencia de los datos reales, evidenciando desviaciones o coincidencias.

En el contexto del problema, la línea azul representa la productividad real de los empleados en cada muestra, mientras que la línea roja discontinua corresponde a las predicciones producidas por el modelo.

Lo anterior, se puede observar en la Fig. 4, donde la línea de los valores predichos no coincide en su mayoría con los valores reales. Mientras que, en la Fig. 5 sucede lo contrario, la línea de valores predichos no llega a cubrir en su totalidad los valores reales. Por su parte, en la Fig. 6, los valores predichos se alinean mejor a los valores reales.

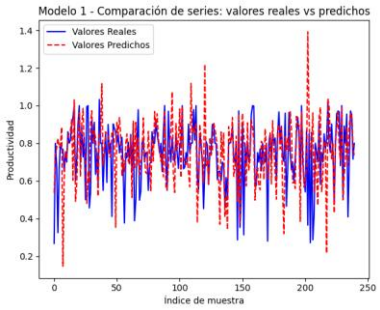

Fig. 4. Gráfica Comparación de Series: Valores Reales vs Predichos del Modelo 1

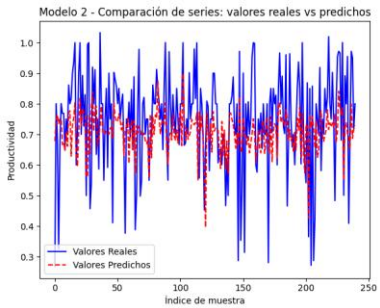

Fig. 5. Gráfica Comparación de Series: Valores Reales vs Predichos del Modelo 2

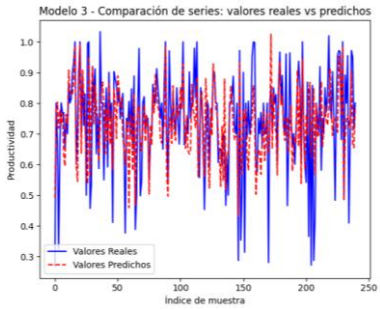

Fig. 6. Gráfica Comparación de Series: Valores Reales vs Predichos del Modelo 3

Por último, se incluyen las gráficas de dispersión de valores reales contra predichos, que representan la relación entre las salidas verdaderas del conjunto de prueba y las predicciones realizadas por el modelo. Aquí, el eje X indica el valor real de la productividad, y el eje Y el valor predicho, además, se agrega una diagonal roja discontinua que representa la predicción ideal sirviendo de referencia. De esta forma, se puede evaluar visualmente que tan acertadas son las predicciones respecto a los valores reales.

La grafica de dispersión del primer modelo, se ilustra en la Fig. 7 donde los puntos de relación están mucho más lejos de la línea ideal, es decir, bastante dispersos.

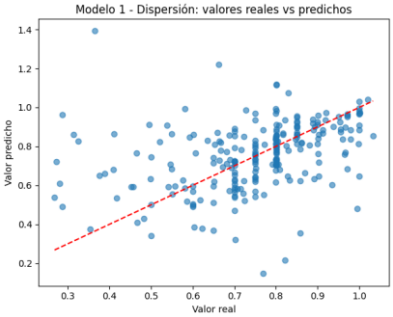

Fig. 7. Gráfica de Dispersión: Valores Reales vs Predichos del Modelo 1

Por otra parte, en el segundo modelo la gráfica muestra puntos más agrupados, pero sin llegar a cubrir la línea en su totalidad, esto se puede observar en la Fig. 8.

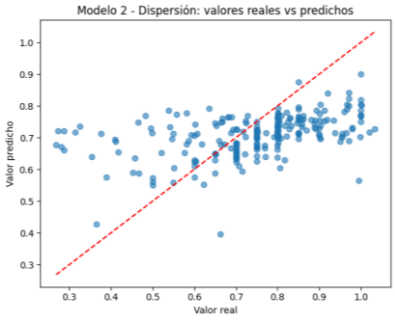

Fig. 8. Gráfica de Dispersión: Valores Reales vs Predichos del Modelo 2

Mientras que, en la gráfica del tercer modelo, los puntos se acercan mucho más a la diagonal abarcando tanto valores altos como bajos como se muestra en la Fig. 9.

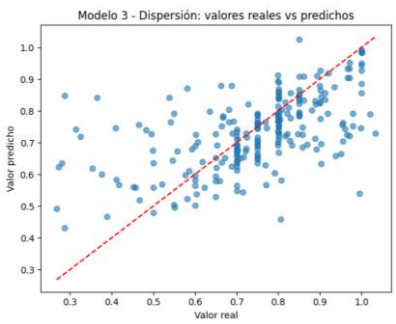

Fig. 9. Gráfica de Dispersión: Valores Reales vs Predichos del Modelo 3

B. *Resultados de la Clasificación MAGIC Gamma Telescope*

En esta sección se presentan los resultados experimentales obtenidos al entrenar y evaluar las tres configuraciones de redes neuronales multicapa (Modelos A, B y C) diseñadas para el problema de clasificación binaria en el conjunto de datos MAGIC Gamma Telescope.

El objetivo principal es distinguir entre eventos de rayos gamma (señal de interés astrofísico) y eventos hadrónicos (ruido de fondo). Por esta razón, en todas las métricas y gráficas se ha tenido en cuenta a gamma como clase positiva, ya que es la que se busca detectar con la mayor sensibilidad posible. De este modo, el recall representa la fracción de eventos gamma detectados correctamente, la precisión indica qué proporción de las predicciones positivas corresponde a verdaderos gamma, y el F1-score resume el compromiso entre ambos. La AUC de la curva ROC se emplea como métrica global de separabilidad, independiente del umbral de decisión.

Los resultados se presentan mediante curvas de pérdida y exactitud por época, matrices de confusión, curvas ROC y tablas de métricas de desempeño.

Empezando por el Modelo A, los resultados fueron los siguientes:

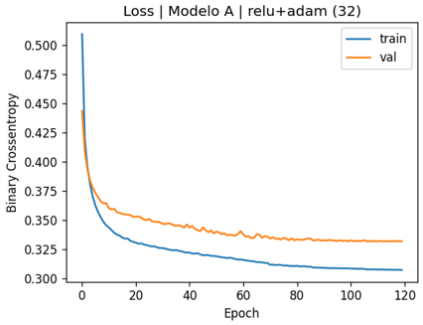

Fig. 10. Curva de perdida en el Modelo A.

En Fig 1. El eje X (épocas) representa ciclos completos sobre los datos de entrenamiento, el eje Y es el BCE, donde los valores menores indican mejor ajuste de probabilidades. El BCE cae de ~0.51 a ~0.30 en “train” y de ~0.44 a ~0.33 en “val”, esta comparación de 0.30 y 0.33 de ambos habla de un sobreajuste leve pero controlado.

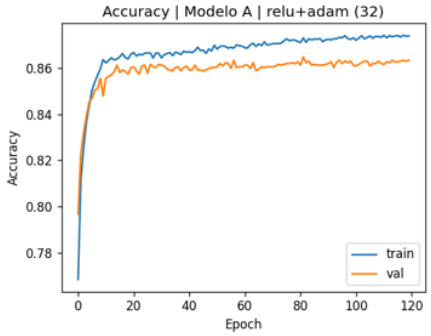

Fig. 11. Curva de exactitud en el Modelo A.

En “Accuaracy” del Modelo A, el eje Y es la proporción de aciertos, la curva “train” refleja el aprendizaje sobre el conjunto de entrenamiento y “val” evalúa en un subconjunto de validación. En este caso, el modelo pasa de ~0.77 a ~0.87 en “train” y ~0.86 en el de validación. Después de ese punto, el rendimiento del modelo se estabiliza, y la curva de exactitud se vuelve casi plana. Esto indica que el modelo ha alcanzado su máximo rendimiento con la configuración actual y que continuar entrenándolo no resultará en mejoras significativas.

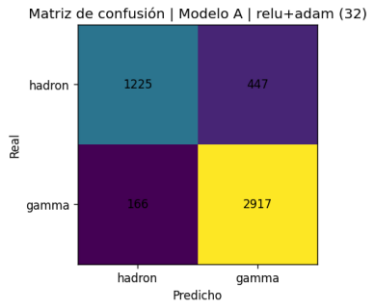

Fig. 12. Matriz de confusion en el Modelo A.

Las matrices de confusión en este trabajo siguen la convención de scikit-learn, donde las filas representan los valores reales y las columnas los valores predichos. Por ello, los verdaderos positivos (TP) aparecen en la esquina inferior derecha y los verdaderos negativos (TN) en la esquina superior izquierda. Esta disposición es equivalente a la convención estándar de TP-FN-FP-TN, pero rotada de forma que las clases reales están en el eje vertical.

Los resultados son: Verdaderos Positivos $(TP) = 2917$, Falsos Positivos$(FP) = 447$, Falsos Negativos $(FN) = 166$ y Verdaderos Negativos $(TN) = 1225$.

Por lo tanto, hablando de la clase positiva "gamma" para la precisión en (5) da un resultado de 0.87, es decir, de todas las veces que el modelo predijo "gamma", acertó en el 87% de los casos. Esto demuestra la confiabilidad del modelo en sus predicciones positivas. Para el Recall (5) de 0.95, el modelo fue capaz de detectar el 95% de todos los eventos "gamma" reales, siguiendo con F1 (5), este tiene resultado de 0.90 que equilibra la precisión y el Recall, refleja un excelente rendimiento general para la clase de interés.

Siguiendo con "hadrón", en precisión obtuvo un 0.88, entonces, cuando el modelo predijo "hadrón", fue muy preciso, con un 88% de aciertos. Y en cuanto al Recall, este es de 0.73, es decir, identifico el 73% de los hadrones reales.

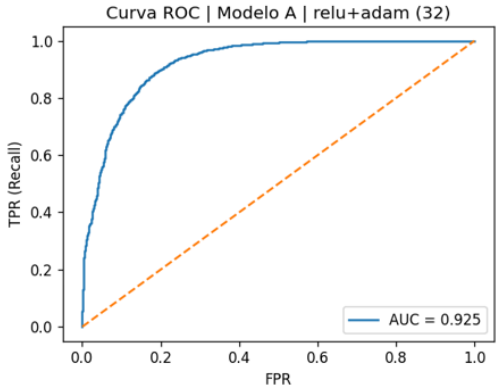

Fig. 13. Curva ROC en el Modelo A.

En Fig 13. En el eje Y tenemos el TPR (recall) y el FPR (FP/FP+TN) en X. La diagonal naranja es un clasificador aleatorio, cuanto más se aleje la curva hacia la esquina superior izquierda indica alta separabilidad a través de distintos umbrales como lo muestra su dato de $AUC = 0.925$.

Pasando al "Modelo B" los resultados fueron los siguientes:

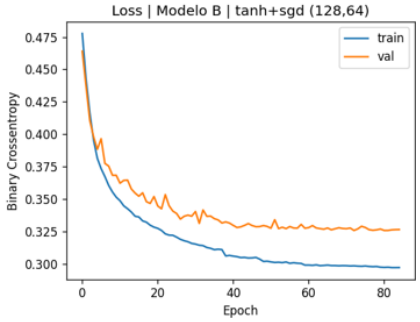

Fig. 14. Curva de perdida en el Modelo B.

En Fig 14. muestra un comportamiento similar al del Modelo A, en este disminuye de manera constante tanto en el conjunto de entrenamiento como en el de validación. La pérdida de validación desciende hasta aproximadamente 0.33, mientras que la de entrenamiento llega a 0.30. Aunque hay una pequeña diferencia entre las dos, no es significativa, entonces el modelo esta aprendiendo de buena manera.

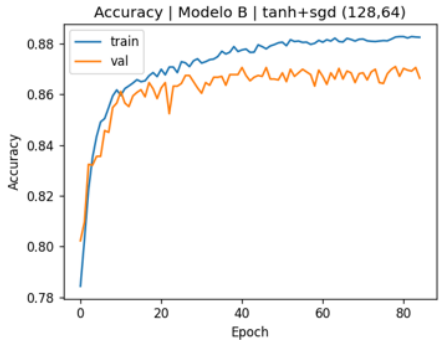

Fig. 15. Curva de exactitud en el Modelo B.

En Fig 15. se puede ver que el rendimiento del modelo aumenta rápidamente al principio y luego se estabiliza. La exactitud de validación se mantiene estable alrededor de 0.866. Los pequeños cambios son un reflejo de que el optimizador SGD (descenso de gradiente estocástico) realiza sus actualizaciones con pequeños grupos de datos, lo que puede causar pequeñas variaciones en el rendimiento.

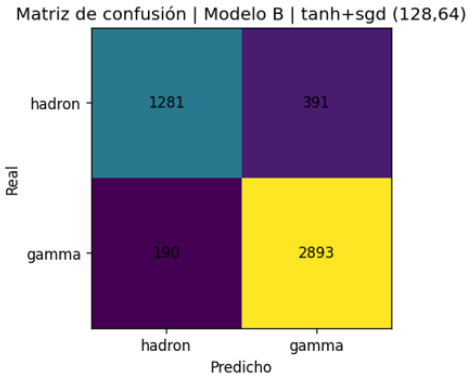

Fig. 16. Matriz de confusion en el Modelo B.

En Fig 16. Están los valores: Verdaderos Positivos (TP) = 2893, Falsos Positivos (FP) = 391, Falsos Negativos (FN) = 190 y Verdaderos Negativos (TN) = 1281.

Por lo tanto, si nos centramos en la clase positiva “gamma”, la precisión (5) es de 0.88. Esto significa que de todas las veces que el modelo predijo "gamma", acertó en el 88% de los casos. En cuanto al recall (5), que es de 0.94, el modelo fue capaz de detectar el 94% de todos los eventos "gamma" reales, demostrando una alta sensibilidad. El F1-score (5) de 0.91 equilibra la precisión y el recall, reflejando un excelente rendimiento general para la clase de interés.

Al analizar la clase "hadrón", el modelo también mostró un buen desempeño. Su precisión (5) fue de 0.87, lo que indica que cuando predijo "hadrón", fue correcto en el 87% de las ocasiones. Sin embargo, su recall (5) fue de 0.77 , lo que significa que identificó correctamente al 77% de los hadrones reales.

Finalmente, la exactitud general del modelo es del 0.88, lo que demuestra una ligera mejora en comparación con el Modelo A.

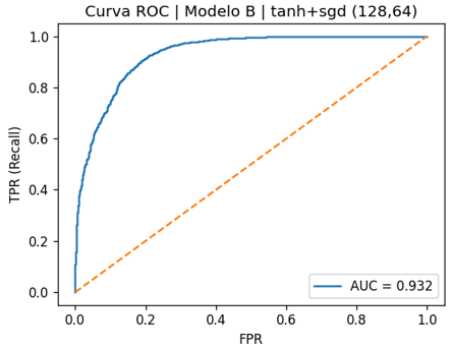

Fig. 17. Curva ROC en el Modelo B.

En Fig 17. la curva del Modelo B domina sobre la de A para un amplio rango de FPR, justificando su AUC superior. Esto quiere decir que hay un mejor equilibrio entre detección de gamma y control de falsos positivos.

Por último el Modelo C:

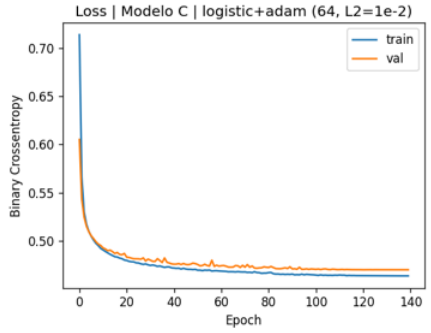

Fig. 18. Curva de perdida en el Modelo C.

En Fig 18. La pérdida de entropía cruzada binaria (BCE) en ambos conjuntos de datos se mantiene en un valor relativamente alto (alrededor de ~0.46), lo que refleja un alto sesgo en el modelo. A diferencia de los modelos anteriores, la fuerte regularización L2 evita que la curva de entrenamiento se separe significativamente de la de validación, lo que indica que el modelo no se está "memorizando" los datos de entrenamiento.

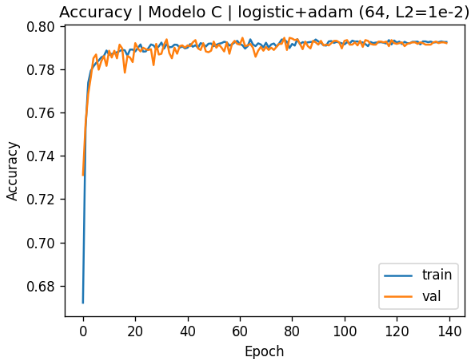

Fig. 19. Curva de exactitud en el Modelo C.

Siguiendo, en Fig 19. Esta muestra las curvas de entrenamiento y validación prácticamente superpuestas, estabilizándose alrededor de 0.79. Esta estabilidad es un resultado directo de la regularización L2, que limita la capacidad del modelo para sobreajustarse y permite que el rendimiento sea casi idéntico en ambos conjuntos de datos. Sin embargo, esta estabilidad se logra a costa de un rendimiento global más bajo, ya que el modelo tiene una menor capacidad de ajuste en comparación con los Modelos A y B.

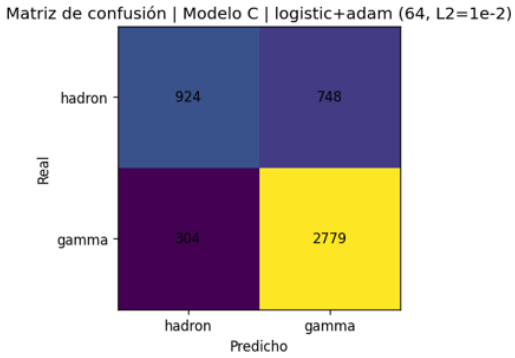

Fig. 20. Matriz de confusion en el Modelo C.

Para la clase positiva 'gamma' en Fig 20, la precisión es de 0.79, lo que significa que el 79% de las predicciones de gamma fueron correctas. El recall es de 0.90, indicando que el modelo detectó el 90% de los eventos gamma reales. Con una puntuación F1 de 0.84, se demuestra que hay un equilibrio entre ambas métricas para la clase de interés.

En cuanto a la clase 'hadrón', el modelo mostró una precisión de 0.75, pero un recall de solo 0.55. Esto significa que el modelo fue menos efectivo detectando hadrones que gamma

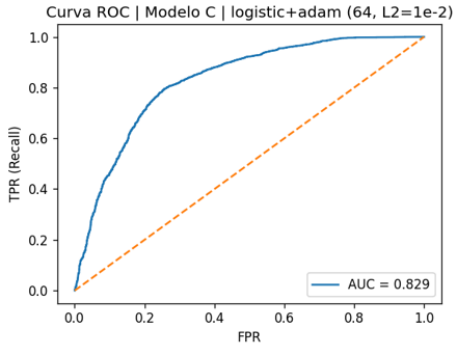

Fig. 21. Curva ROC en el Modelo C.

La curva ROC del Modelo C en Fig 21, su valor de AUC confirman que su rendimiento es inferior en comparación con los Modelos A y B. El gráfico muestra que la curva del Modelo C se ubica por debajo de las de los otros modelos, lo que significa que el modelo requiere una tasa más alta de falsos positivos (FPR) para alcanzar una tasa de verdaderos positivos (TPR) similar a la de sus contrapartes.

Este comportamiento es un reflejo directo del valor del AUC, que para el Modelo C es de 0.829. Un AUC más bajo indica una menor capacidad del modelo para separar de manera efectiva las clases 'gamma' y 'hadrón', lo que se traduce en un desempeño de clasificación global menos eficiente.

Por último, está la tabla comparativa formada por F1-Score

TABLE III. COMPARACIÓN DE LOS MODELOS EN CLASIFICACION (F1-SCORE)

Modelo	Accuracy	Precision	Recall
Modelo B (tanh + sgd)	0.877813	0.880938	0.938372
Modelo A (relu + adam)	0.871083	0.867122	0.946156
Modelo C (logistic + adam)	0.778759	0.787922	0.901395

Según la tabla comparativa, el Modelo B es el que presenta el mejor rendimiento general. Ocupa el primer lugar con la exactitud más alta (~0.88), una precisión de ~0.88 y un recall de ~0.94.

El Modelo A le sigue muy de cerca, demostrando un rendimiento sólido. Aunque su exactitud (~0.87) es ligeramente inferior, presenta un recall un poco más alto (~0.95), lo que indica una mejor capacidad para identificar todos los eventos gamma.

Finalmente, el Modelo C muestra el rendimiento más bajo en todas las métricas. Con una exactitud de ~0.78, una precisión de ~0.79 y un recall de ~0.90, sus valores confirman que la regularización excesiva afectó negativamente su capacidad de aprendizaje y generalización, resultando en un desempeño menos efectivo en comparación con los otros dos modelos.

V. DISCUSIÓN

De acuerdo con los resultados obtenidos, en esta sección se presenta un análisis crítico que interpreta el significado de las métricas calculadas y lo que indican las gráficas generadas durante el experimento. Esto con el objetivo de extraer conclusiones más sólidas sobre la capacidad de predicción y clasificación de los modelos diseñados.

A. Discusión de la Predicción de Productividad en la Industria Textil (Regresión)

Partiendo por la comparación de las métricas evaluadas en la Tabla 2, se puede decir que el primer modelo no muestra un buen desempeño ya que presenta un coeficiente de determinación negativo, lo que indica que el modelo esta peor que una predicción constante. Esto a pesar de que los valores de los errores son pequeños y se encuentran en un rango aceptable.

Por su parte, el segundo modelo presenta una mejora significativa, pues sus errores siguen siendo pequeños, estando dentro del rango aceptado. Además, su coeficiente de determinación aumento a 0.1624, lo que significa que el modelo comenzó a capturar la variabilidad del problema.

Finalmente, el tercer modelo mejora aún más que el anterior, manteniendo los valores de los errores dentro del rango aceptable y aumentando el coeficiente de terminación aproximadamente a 0.3, acercándose a la predicción ideal $(1,0)$, esto significa que el modelo está representando mejor la variabilidad del problema.

Siguiendo con las curvas de pérdida, donde cada figura refleja el desempeño de un modelo específico, en la Fig. 1 se puede inferir que la red aprendió patrones básicos con facilidad, ya que el modelo presenta una rápida disminución tanto en el entrenamiento como en la validación en las primeras épocas. Sin embargo, durante el proceso restante, la curva de validación deja de mejorar aumentando la diferencia con la curva de entrenamiento, ya que esta sigue disminuyendo. Esto sugiere que el modelo tiene a sobreajustarse, lo que no le permite generalizar los datos de validación correctamente.

Mientras que en la Fig. 2, las curvas de entrenamiento y validación descienden de manera más sincronizada, alcanzando valores bajos rápidamente. Ambas se mantienen cercanas y estables, lo que refleja un aprendizaje más equilibrado, reduciendo el riesgo de enfrentar el sobreajuste. En resumen, el segundo modelo tiene un buen ajuste rápido.

Asimismo, en la Fig. 3 la curva de perdida en el entrenamiento y en la validación muestran muestra una disminución abrupta en las primeras épocas, para luego, gradualmente ir descendiendo con menos rapidez, lo que indica una convergencia lenta por su traza de aprendizaje pequeña. Además, aunque ambas se mantienen cerca durante todo el proceso, la curva de validación presenta pequeñas fluctuaciones. Sin embargo, el comportamiento de las curvas evidencia que es un modelo con un buen ajuste y estable, ya que no presenta riesgos de sobreentrenamiento.

En el caso de las gráficas de comparación de series, de acuerdo a lo observado en la Fig. 4, el primer modelo muestra que aunque las predicciones tratan de seguir la tendencia de los valores reales, presenta varias desviaciones en las curvas, lo que siguiere que el modelo no lograra representar las variaciones de la productividad adecuadamente, este análisis se refuerza con los resultados de las métricas donde el coeficiente de determinación negativo indica baja precisión predictiva como se mencionó anteriormente.

En la Fig. 5, se observa una mejor correspondencia entre los valores reales y los predichos, aunque las curvas datos predichos no coinciden en su totalidad, cubriendo solo la parte central sin abarcar bien los picos y valles. Esto indica que las modificaciones en la arquitectura (más neuronas, *Dropout*, y taza de aprendizaje mayor) ayudaron a mejorar el

desempeño del modelo, aumentando su capacidad para aprender correctamente.

A diferencia de los modelos anteriores, el tercer modelo produce una dinámica más acorde, ya que como se muestra en la Fig. 6, las predicciones se ajustan mejor a los datos reales, mostrando menor desviación y un seguimiento más consistente con los picos y valles de la serie. Esto refleja un progreso positivo en la capacidad predictiva, aunque se puede mejorar la precisión. Además, como se mencionó antes, su valor de R^2 evidencia el buen desempeño de esta arquitectura.

Finalmente, las gráficas de dispersión de los valores reales contra los predichos. En la Fig. 7, se observa como los datos predichos son más variables frente a los reales, ya que muchos de los puntos se encuentran lejos de la línea ideal. Este modelo presenta una dispersión amplia, lo que refleja un bajo nivel de ajuste y explica el coeficiente de determinación negativo.

En el caso del segundo modelo, la Fig. 8 muestra como los valores predichos tienen a agruparse en un rango reducido, subestimando los valores altos, lo que evidencia que el modelo produce predicciones similares sin representar correctamente la variabilidad de los datos reales. Además, los puntos están un poco alejados de la línea ideal a pesar de presentar una buena curva de perdida, esto siguiere que el nivel de ajuste aun no es el mejor.

Por último, en la Fig. 9 se muestra que los puntos se acercan más a la diagonal roja, indicando una ligera mejora respecto a los modelos anteriores. Esto confirma que la arquitectura del tercer modelo captura mejor la relación entre los valores reales y predichos, sin embargo, aún existe una dispersión considerable, lo que lleva a plantear que el modelo comprende parcialmente la tendencia de los datos, pero presenta dificultades para generalizarlos.

B. Discusion de MAGIC Gamma Telescope (Clasificación)

Los tres modelos que se probaron en clasificación (A, B y C) presentaron buenos comportamientos con las configuraciones de hiperparámetros seleccionadas. El Modelo A nos sirvió como punto de partida. A pesar de ser el más simple, con una arquitectura de baja complejidad, demostró ser una solución muy buena y eficiente. Logró un excelente equilibrio entre la precisión y el recall, y su AUC fue de 0.925.

Al hacer el Modelo B más complejo, agregando más capas y neuronas y cambiando el optimizador, se evidenció una pequeña pero importante mejora. La precisión y el F1 subieron un poco, y el AUC llegó a 0.932. Esto dice que una red más profunda puede separar mejor las clases, y el optimizador SGD con momentum ayudó a que el modelo encontrara el mejor camino para aprender. Aun así, las curvas mostraron algunas oscilaciones, algo normal con este tipo de optimizador.

Por otro lado, el Modelo C nos mostró qué pasa cuando se usa una regularización. Aunque las curvas de entrenamiento y validación se mantuvieron muy juntas, evitando el sobreajuste, el rendimiento general del modelo fue mucho peor. La exactitud bajó a 0.78 y el AUC a 0.829. Esto prueba que una penalización L2 demasiado alta puede ser contraproducente, ya que limita la capacidad del modelo para aprender de manera efectiva.

VI. Conclusiones

El desarrollo de este trabajo permitió implementar redes neuronales multicapa (MPL) para resolver problemas reales de regresión y clasificación, donde se requería predecir la productividad de los empleados en la industria textil y clasificar eventos que detecta un telescopio Cherenkov en tierra. Esto por medio de la construcción de tres modelos diferentes por cada problema, variando la configuración de sus hiperparámetros. Esto con el fin de practicar el proceso de preparación de datos, definición de arquitectura, entrenamiento, validación y evaluación de desempeño con métricas.

En el caso de la predicción de productividad, los resultados obtenidos evidencian, que, si bien los modelos lograron aprender la tendencia básica de los datos reales, su capacidad para predecir aun presenta obstáculos a superar, siendo el tercer modelo el que presento mejor desempeño con un R^2 aproximado a 0.3, seguido del segundo modelo logrando resultados estables, mientras que el primer modelo, al carecer de regularización, cae en sobreajuste y muestra un desempeño deficiente en la validación.

Lo anterior, siguiere la dificultad que se enfrentó para que los modelos lograran representar la tendencia de los datos reales, a pesar del procesamiento de los datos para depurarlos al máximo. Lo que lleva a considerar también, que existen valores y variables ruidosas en el dataset que no aportaban mucho para permitir que modelo aprendiera correctamente.

Con ello en mente, se destaca la relevancia que tiene la función de perdida y las métricas en la interpretación de resultados, ya que gracias a ellas se puede identificar el nivel de desempeño que está presentando el modelo y comenzar a realizar ajustes en la arquitectura. Además, la utilidad de técnicas como la regularización y los *callbacks* para controlar el sobreajuste en el proceso, y de esta forma optimizar la predicción.

Por otro lado, en el caso de la clasificación, se permitió evidenciar cómo la elección de hiperparámetros impacta de forma significativa el desempeño de redes neuronales en tareas de clasificación binaria. Con el conjunto de datos MAGIC Gamma Telescope se demostró que el Modelo B con mayor profundidad y optimizador SGD con momentum obtuvo el mejor rendimiento global, con el mayor F1 y AUC, confirmando que una mayor capacidad de representación puede mejorar la separación entre clases.

El Modelo A, más simple, logró resultados competitivos, lo que lo hace adecuado para escenarios donde la eficiencia computacional es prioritaria. En contraste, el Modelo C mostró que una regularización excesiva puede conducir al subajuste, reduciendo la capacidad predictiva del modelo.

En general, se aprendió que es fundamental encontrar un equilibrio entre complejidad, optimización y regularización para obtener modelos que generalicen bien. Además, se reafirmó la importancia de emplear métricas como F1-score y AUC para evaluar de forma justa el desempeño en conjuntos de datos desbalanceados.

REFERENCIAS

[1] DataCamp, "*Multilayer Perceptrons in Machine Learning*," tutorial en línea. Consultado: 18-sept-2025. Disponible en: https://www.datacamp.com/es/tutorial/multilayer-perceptrons-in-machine-learning

[2] UCI Machine Learning Repository, "*Productivity Prediction of Garment Employees*," conjunto de datos. Consultado: 18-sept-2025. Disponible en: https://archive.ics.uci.edu/dataset/597/productivity+prediction+of+garment+employees

[3] Brightbytee (Medium), "*Loss Functions in Deep Learning: Everything You Need to Know*," artículo en línea. Consultado: 18-sept-2025. Disponible en: https://brightbytee.medium.com/loss-functions-in-deep-learning-everything-you-need-to-know-2cd63fcc5478

[4] Clarity, "*R^2 & RMSE*," nota de conocimiento en línea. Consultado: 18-sept-2025. Disponible en: https://click.clarity.io/knowledge/r2-rmse

[5] UCI Machine Learning Repository, "*MAGIC Gamma Telescope Dataset*," conjunto de datos. Consultado: 18-sept-2025. Disponible en: https://archive.ics.uci.edu/dataset/159/magic+gamma+telescope

[6] DataCamp, "*AUC: Area Under the ROC Curve*," tutorial en línea. Consultado: 18-sept-2025. Disponible en: https://www.datacamp.com/es/tutorial/auc

[7] DataScientest, "*Matriz de confusión*," artículo en línea. Consultado: 18-sept-2025. Disponible en: https://datascientest.com/es/matriz-de-confusion

[8] F. Algo (Medium), "*Optimization Algorithm: From SGD to Adam*," artículo en línea. Consultado: 18-sept-2025. Disponible en: https://medium.com/@florian_algo/optimization-algorithm-from-sgd-to-adam-50ea22187951

[9] DigitalOcean, "*Intro to Optimization: Momentum, RMSProp, Adam*," tutorial en línea. Consultado: 18-sept-2025. Disponible en: https://www.digitalocean.com/community/tutorials/intro-to-optimization-momentum-rmsprop-adam

[10] O. Ankeli (Medium), "*Understanding Regularization Techniques in Machine Learning: L1, L2, Dropout, Data Augmentation*," artículo en línea. Consultado: 18-sept-2025. Disponible en: https://medium.com/@o.ankeli/understanding-regularization-techniques-in-machine-learning-l1-l2-dropout-data-augmentation-7a8f61b95e8f

[11] Codificando Bits, "*Función de activación*," artículo en línea. Consultado: 18-sept-2025. Disponible en: https://codificandobits.com/blog/funcion-de-activacion/

[12] Keras, "*Keras Documentation*," documentación oficial en línea. Consultado: 18-sept-2025. Disponible en: https://keras.io